

密级状态：绝密( ) 秘密( ) 内部( ) 公开(√)

## RKNN-Toolkit FAQ

(技术部，图形显示平台中心)

文件状态： [ ] 正在修改 [√] 正式发布	当前版本：	0.9
	作 者：	HPC
	完成日期：	2019/4/1
	审 核：	卓鸿添
	完成日期：	2019/4/1

福州瑞芯微电子股份有限公司

Fuzhou Rockchips Semiconductor Co., Ltd

(版本所有,翻版必究)

## 更新记录

版本	修改人	修改日期	修改说明	核定人
0.9	HPC	2019/4/1	初稿	卓鸿添

## 目录

1. RKNN Toolkit 用法相关问题 .....	4
2. 关于量化精度的问题 .....	9
3. Caffe 模型转换常见问题 .....	10
4. Tensorflow 模型转换常见问题 .....	12
5. Pytorch 模型转换常见问题 .....	12

## 1. RKNN Toolkit 用法相关问题

### 1.1. rknn.config 函数，为什么 channel\_mean\_value 有 4 个值？如果是 rgb 图像，还是 4 个值吗？

rknn.config 里面的 channel-mean-value: 用来设置预处理的命令行参数。包括四个值(M0 M1 M2 S0),前三个值为均值参数,后面一个值为 Scale 参数。对于输入数据是三通的(Cin0, Cin1, Cin2)数据来讲,经过预处理后,输出的数据为(Cout0,Cout1, Cout2),计算过程如下:

$$\text{Cout0} = (\text{Cin0} - \text{M0})/\text{S0}$$

$$\text{Cout1} = (\text{Cin1} - \text{M1})/\text{S0}$$

$$\text{Cout2} = (\text{Cin2} - \text{M2})/\text{S0}$$

例如,如果需要将输入数据归一化到[-1, 1]之间,则可以设置这个参数为(128 128 128 128);

如果需要将输入数据归一化到[0, 1]之间,则可以设置这个参数为 (0 0 0 255)。

### 1.2. 当输入图像是单通道灰度图片时， rknn.config 接口如何设定

请参考 1.1 的回答，当输入图像是单通道时，只用到“Cout0 = (Cin0 - M0)/S0”，因此你可以设置为(M0, 0, 0, S0)，M1、M2 的值不会被用到。

### 1.3. rknn.config 函数，怎么设定 scale 参数，即把输入的 range 压缩到一定的范围。e.g. from (0-255) to (0-1)

参考 1.1 的回答。

### 1.4. rknn.Inference()接口调用多次后出错或者卡住

如果出错信息类似：

```
Traceback (most recent call last):
  File "rknn_pic_to_emb.py", line 63, in <module>
  File "rknn_pic_to_emb.py", line 42, in get_embedding
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/site-packages/rknn/
api/rknn.py", line 234, in inference
  File "rknn/api/redirect_stdout.py", line 76, in rknn.api.redirect_stdout.redir
ect_stdouter.redirect_stdout.func_wrapper
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/contextlib.py", lin
e 81, in __enter__
  File "rknn/api/redirect_stdout.py", line 48, in stdout_redirector
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/tempfile.py", line
622, in TemporaryFile
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/tempfile.py", line
262, in _mkstemp_inner
OSError: [Errno 24] Too many open files: '/tmp/tmp5yw4m_22'
Traceback (most recent call last):
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/weakref.py", line 6
24, in _exitfunc
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/weakref.py", line 5
48, in _call_
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/tempfile.py", line
799, in _cleanup
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/shutil.py", line 48
2, in rmtree
  File "/home/etest/.conda/envs/tensorflow_env/lib/python3.6/shutil.py", line 48
0, in rmtree
OSError: [Errno 24] Too many open files: '/tmp/tmp_d63w4jh'
```

请将 RKNN Toolkit 升级到 0.9.9 及以后。

## 1.5.rknn.inference()推理速度慢的问题

这个问题有两方面的现象：

- 1) 进行前向推理测试速度慢，经测试 mobilenet-ssd 有的图片耗时在 0.5 秒以上
- 2) 模型 rknn.inference 的时间和 rknn.eval\_perf()时间相差较大，比如

理论计算时间(单图)	1.79ms	8.23ms	7.485ms	30.55ms
实际计算时间(单图)	21.37ms	39.82ms	33.12ms	76.13ms

实测帧率慢的问题，有两方面的原因：

1. 使用 pc + adb 的方式传图片比较慢，这种对高帧率的网络影响很大比如理论 1.79ms 的网络。
2. RKNN Toolkit 0.9.8 及以前的版本的实现有 BUG，这个问题在 0.9.9 中已经解决。

对于更真实的实测帧率，可以直接在板子上使用 c/c++ api 进行测试。

## 1.6.RKNN Toolkit 0.9.9 版本第一次 inference 很慢

RKNN Toolkit 0.9.9 版本将加载模型推迟到第一次 inference 时，因此第一次 inference 比较慢，这个问题将在下个版本中解决。

## 1.7.在开发板上用 RKNN Toolkit 转换模型时开启 pre\_compile=true 出错

Arm64 版本的 RKNN Toolkit 暂时还不支持 pre\_compile，如果需要打开 pre\_compile，建议在开发机上用 x86 版本 RKNN Toolkit 进行转换。

## 1.8.YOLO 前向测试返回的 outputs 为[array1 , array2]，长度分别为[10140 , 40560]，返回值含义是什么

rknn.inference 返回的 outputs 是一个 numpy ndarray 的列表，每个模型输出数据大小个数都不一样，用户需要自行查找模型的对应输出和解析规则。

## 1.9.RKNN Toolkit 支持的量化方式

RKNN 支持两种量化机制：

- **Quantization-aware training**

可以参考 Tensorflow quantization-aware training

(<https://github.com/tensorflow/tensorflow/tree/master/tensorflow/contrib/quantize>)，这种方法要求用户有一定的 fine tune 重训练的基础。使用 RKNN Toolkit 导入量化后的模型时使用 rknn.build(do\_quantization=False)，这时 RKNN Toolkit 将使用模型自身的量化参数，因此在量化精度上不会有损失。

- **Post training quantization**

使用这种方式时，用户导入已训练好的 float point 模型，RKNN Toolkit 根据用户提供的 dataset 进行量化。Dataset 应尽量覆盖模型可能的输入类型。官方提供的 example 为了简单一般只放一张图片，建议多放一些。

目前 RKNN Toolkit 支持 3 种量化方式：

- ✓ asymmetric\_quantized-u8 (default)

这是 tensorflow 支持的量化方式，也是 google 推荐的。根据”[Quantizing deep convolutional networks for efficient inference: A whitepaper](#)” 论文的描述，对于大部分网络，这种量化方式对精度的损失最小。

其计算公式如下：

$$\text{quant} = \text{round}\left(\frac{\text{float\_num}}{\text{scale}}\right) + \text{zero\_point}$$
$$\text{quant} = \text{cast\_to\_bw}$$

其中 quant 代表量化后的数，float\_num 代表 float，scale 是一个 float32 类型，zero-points 是一个 int32 类型，代表实数为 0 时对应的量化值，最后把 quant 饱和到【range\_min, range\_max】

$$\text{range\_max} = 255$$
$$\text{range\_min} = 0$$

因为当前只支持 u8

对应的反量化

$$\text{float\_num} = \text{scale}(\text{quant} - \text{zero\_point})$$

✓ dynamic\_fixed\_point-8

对于有些模型而言，dynamic\_fixed\_point-8 量化的精度比 asymmetric\_quantized-u8 高。

其公式如下

$$\text{quant} = \text{round}(\text{float\_num} * 2^{\text{fl}})$$
$$\text{quant} = \text{cast\_to\_bw}$$

其中 quant 代表量化后的数，float\_num 代表 float，fl 是左移的 bits，最后把 quant 饱和到【range\_min, range\_max】

$$\text{range\_max} = 2^{bw-1} - 1$$
$$\text{range\_min} = -(2^{bw-1} - 1)$$

若 bw=8，则范围在[-127, 127]

✓ dynamic\_fixed\_point-16

dynamic\_fixed\_point-16 的量化公式与 dynamic\_fixed\_point-8 一样，只不过 bw=16。对于 rk3399pro/rk1808 而言，NPU 里面都带有 300Gops int16 的计算单元，对于某些量化到 8 位精度损失较大的网络，可以考虑使用此量化方式。

### 1.10. 转换模型时如果 do\_quantization 为 False，是否也会进行量化，量化精度是什么？（因为转换后模型体积小了接近一半）

分两种情况，当导入的模型是量化的模型时，do\_quantization=False 会使用该模型里面的量化参数，具体请参考 1.9 的回答。当导入的模型是非量化模型时，do\_quantization=False 不会做量化的操作，但是会把权重从 float32 转成 float16，这块不会有精度损失。



### 1.11. 构建 RKNN 模型（调用 build 接口）时，设置 do\_quantization=False 能构建成功，但是设成 True，构建失败

错误信息如下:

```
T Caused by op 'fifo_queue_DequeueMany', defined at:
T   File "test.py", line 52, in <module>
T   ret = rknn.build(do_quantization=True, dataset='./dataset.txt')
T   File "/home/ljq1/work/rock3399pro/RKNNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/rknn/api/rknn.py", line 162, in build
T   ret = self.rknn_base.build(do_quantization=do_quantization, dataset=dataset, pack_vdata=pre_compile)
T   File "/home/ljq1/work/rock3399pro/RKNNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/rknn/base/rknnlib/app/tensorzone/tensorprovider.py", line 154, in get_output
T   return self.queue_task.queue.dequeue_many(batch_size)
T   File "/home/ljq1/work/rock3399pro/RKNNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/ops/data_flow_ops.py", line 478, in dequeue_many
T   self.queue_ref, n=n, component_types=self.dtypes, name=name)
T   File "/home/ljq1/work/rock3399pro/RKNNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/ops/gen_data_flow_ops.py", line 3487, in queue_dequeue_many_v2
T   component_types=component_types, timeout_ms=timeout_ms, name=name)
T   File "/home/ljq1/work/rock3399pro/RKNNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/framework/op_def_library.py", line 787, in _apply_op_helper
T   op_def=op_def)
T   File "/home/ljq1/work/rock3399pro/RKNNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/util/deprecation.py", line 488, in new_func
T   return func(*args, **kwargs)
T   File "/home/ljq1/work/rock3399pro/RKNNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/framework/ops.py", line 3274, in create_op
T   op_def=op_def)
T   File "/home/ljq1/work/rock3399pro/RKNNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/tensorflow/python/framework/ops.py", line 1770, in __init__
T   self._traceback = tf_stack.extract_stack()
T OutOfRangeError (see above for traceback): FIFOQueue '_0_fifo_queue' is closed and has insufficient elements (requested 1, current size 0)
T [[node fifo_queue_DequeueMany (defined at /home/ljq1/work/rock3399pro/RKNNPUTools/0.98/rknn-toolkit/venv/lib/python3.5/site-packages/rknn/base/rknnlib/app/tensorzone/tensorprovider.py:154) = QueueDequeueManyV2[_class=["loc:[input_116/cond/Switch_2]", component_types=[DT_FLOAT, DT_INT32], timeout_ms=-1, _device="/job:localhost/replica:0/task:0/device:CPU:0"]](fifo_queue, fifo_queue_DequeueMany/n)]]
Build onnx failed!
```

这是由于 dataset.txt 里没有数据，或者数据是我们不支持的格式，建议用 jpg 或 npv。

### 1.12. 安装 RKNN-Toolkit 时出现”undefined symbol: PyFPE\_jbuf”错误

出现这个错误的原因是 Python 环境不干净, 比如在两个不同的路径里都安装了 numpy。

可以重新创建一个干净的 Python 环境后再试。

### 1.13. 在 Toybrick 上安装 RKNN-Toolkit 出现 “Permission Denied” 错误。

原因是没有 root 权限，安装的时候需要加上 '--user' 选项。

### 1.14. RKNN 是否多输入的模型转换?

目前不支持多输入模型转换，该功能正在评估中。

### 1.15. RKNN 量化过程中的 dataset 起什么作用？为什么量化需要和 dataset 关联？

RKNN 量化过程中，需要找到合适的量化参数，比如 scale 或者 zero point，这些量化参数的选择需要根据实际的输入做 inference 来确定。



## 1.16. rknn.inference()是否支持同时输入多张图片？或者说支持 batch 输入。

目前不支持同时输入多张图片。

## 1.17. 什么时候能支持 pytorch 和 mxnet 模型直接转成 rknn？

Pytorch 直接转换成 rknn 的功能正在开发中，mxnet 暂时没有计划。

## 2. 关于量化精度的问题

### 2.1. 量化后精度与原来模型对不上，如何调试？

➤ 首先确保 float 类型的精度和原始平台测试结果相近：

- (1) 使用 RKNN Toolkit 导入量化后的模型时使 `rknn.build(do_quantization=False)`;
- (2) 参考 1.1 设置 `channel_mean_value` 参数，确保其和训练模型时使用的参数相同;
- (3) 务必确保测试时输入图像通道顺序为 R,G,B。（不论训练时使用的图像通道顺序如何，使用 RKNN 做测试时都按 R,G,B 输入）

(4) 在 `rknn.config` 函数里面设置 `reorder_channel` 参数，'0 1 2'代表 RGB，'2 1 0'代表 BGR，务必和训练时候图像通道顺序一致

➤ 量化后的精度测试

- (1) 使用多张图进行量化，确保量化精度稳定。

在 `rknn.config` 中设置 `batch_size` 参数（建议设置 `batch_size = 200`）并且在 `dataset.txt` 中给出大于 200 张图像路径用于量化。

如果显存不够，可以设置 `batch_size=1`, `epochs=200` 代替 `batch_size = 200` 进行量化

- (2) 精度对比，尽量用较大数据集进行测试。分类网络比较 top-1,top-5 精度，检测网络比较数据集的 mAP, Recall 等。

### 2.2. 如何 dump 网络每层输出

目前 PC 模拟器可以支持 dump 出每一层网络的数据，在执行 inference 的脚本前需要设置一个环境变量，命令如下：

```
export NN_LAYER_DUMP=1
```

```
python xxx.py
```

执行完之后，会在当前目录生成每层网络的 tensor 数据文件，这样可以和别的框架的

数据进行逐层比对。

注意：有些层会被合并，比如 conv+bn+scale 会合并成一个 conv，这时候就需要和原来模型的 scale 层的输出进行对比。

### 3. Caffe 模型转换常见问题

#### 3.1. 转换模型时，出现“Deprecated caffe input usage”错误

该模型是旧版的 caffe 的模式，需要修改输入层成如下类似格式。

```
layer {
  name: "data"
  type: "Input"
  top: "data"
  input_param {
    shape {
      dim: 1
      dim: 3
      dim: 224
      dim: 224
    }
  }
}
```

#### 3.2. 转换模型时，出现“Message type "caffe.PoolingParameter" has no field named "round\_mode"”错误

Pool 层的 round\_mode 字段不能识别，可以改成 ceil\_model，比如原来是 round\_mode: CEIL，那么可以删掉（默认 ceil\_mode 为 True）或者改成 ceil\_mode:True。

#### 3.3. 在进行 caffe 或者其他模型转换时，出现“ValueError('"%s' is not a valid scope name" % name)”的错误

详细的错误信息类似如下：

```
T      raise ValueError('"%s' is not a valid scope name" % name)
T ValueError: '_plus0_17' is not a valid scope name
```

对于这种情况是因为：layer name '\_plusxxx' 用下划线开头不合法，要遵循 tensorflow 的命名规则：

[A-Za-z0-9.][A-Za-z0-9.\_\\-/]\* (for scopes at the root)

[A-Za-z0-9.\_\\-/]\* (for other scopes)

### 3.4.Caffe 版本的 SSD 转换失败，出现 “Invalid tensor id(1), tensor(@mbox\_conf\_flatten\_188:out0)” 的错误

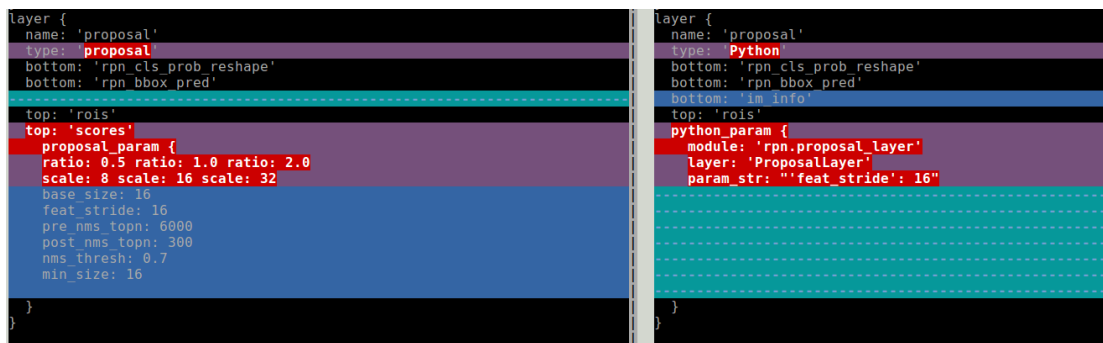
不支持 detectionoutput 这个 layer，可以删掉，改成在 CPU 做。

### 3.5.Caffe 版本的 SSD 模型去掉 detectionoutput 后应该有 3 个 output tensor，但 RKNN 推理时实际只返回两个 tensor

这个缺失的 tensor 是先验框，它在训练、推理阶段都一样，且对所有输入都一样，为了提高性能，RKNN-Toolkit 在模型中将相关的层优化掉了。而要得到该先验框 tensor，可以在训练阶段将先验框的 tensor 保存下，或者用 Caffe 先 inference 一次。

### 3.6.py-faster-rcnn 模型转换时出现 “ValueError: Invalid tensor id(1), tensor(@rpn\_bbox\_pred\_18:out0)” 错误

与官方相比需要修改 prototxt 中的 'proposal' 层如下：



```

layer {
  name: 'proposal'
  type: 'proposal'
  bottom: 'rpn_cls_prob_reshape'
  bottom: 'rpn_bbox_pred'
  top: 'rois'
  top: 'scores'
  proposal_param {
    ratio: 0.5 ratio: 1.0 ratio: 2.0
    scale: 8 scale: 16 scale: 32
    base_size: 16
    feat_stride: 16
    pre_nms_topn: 6000
    post_nms_topn: 300
    nms_thresh: 0.7
    min_size: 16
  }
}

```

## 4. Tensorflow 模型转换常见问题

### 4.1. 转换 google 官方的 ssd\_mobilenet\_v2 模型出现 “AttributeError: ‘NoneType’ object has no attribute op” 错误

一个可能的原因是 input 节点没有取对，可以改成如下：

```
rknn.load_tensorflow(tf_pb='./ssd_mobilenet_v2_coco_2018_03_29/frozen_inference_graph.pb',  
                     inputs=['FeatureExtractor/MobilenetV2/MobilenetV2/input'],  
                     outputs=['concat', 'concat_1'],  
                     input_size_list=[[INPUT_SIZE, INPUT_SIZE, 3]])
```

### 4.2. 转换 SSD\_Resnet50\_v1\_FPN\_640x640 模型出现“Cannot convert value dtype (['resource', 'u1']) to a Tensorflow Dtype” 错误。

需更新 RKNN Toolkit 到 0.9.8 及以后版本。

## 5. Pytorch 模型转换常见问题

目前 RKNN Toolkit 通过 ONNX 间接支持 pytorch，因此需要将 pytorch 先转成 ONNX。如果转换过程遇到问题，请先将 RKNN Toolkit 升级到最新版本。

### 5.1. 转换时遇到类似 “assert(tsr.op\_type == 'Constant')” 的错误

这是 pytorch 0.4.5 以后的版本引入的问题，在你的模型中，有类似 “x = x.view(x.size(0), -1)” 这样的语句，需要改成 “x = x.view(int(x.size(0)), -1)”。